

Proyecto 2: PageRank sobre redes reales

La red de hipervínculos de la Wikipedia en kashubio (csb)

Álgebra Lineal Avanzada y Modelamiento – IMT2230
Pontificia Universidad Católica de Chile

Grupo: Bastián Pérez, Martín Pérez, Felipe Serrano

July 7, 2026

Abstract

Aplicamos el algoritmo PageRank a la red de hipervínculos de la Wikipedia en kashubio (KONECT, `wikipedia_link_csb`), una red dirigida de 5 561 artículos y 191 255 enlaces. Construimos explícitamente la matriz de hipervínculos H , su versión columna-estocástica S y la Matriz de Google G , calculamos PageRank mediante iteración de potencias implementada desde cero, y comparamos los resultados con el grado de entrada de cada nodo. Encontramos una correlación de Pearson moderada (0.38) entre PageRank e in-degree, y evidencia clara de que la importancia recursiva de PageRank captura información estructural que el conteo simple de enlaces no captura.

1 P1 – Elección y descripción de la red

Red elegida: *Wikipedia links (csb)*, disponible en KONECT (http://konect.cc/networks/wikipedia_link_csb/).

Nodos: artículos de la Wikipedia en **kashubio**, una lengua eslava minoritaria hablada en el norte de Polonia (código ISO **csb**).

Aristas dirigidas: existe una arista $u \rightarrow v$ si el artículo u contiene un hipervínculo hacia el artículo v .

Contexto de recolección: KONECT extrajo la red directamente de un volcado (*dump*) de `dumps.wikimedia.org`. Es una red de hipervínculos web clásica.

Por qué la elegimos: cumple los mínimos exigidos ($n \geq 500$, $m \geq 2000$, dirigida), y al ser una Wikipedia de tamaño moderado, es más fácil de visualizar el subgrafo de nodos con mayor PageRank (P7). Una limitación relevante: este dataset de KONECT no incluye los títulos de los artículos, solo identificadores internos de Wikipedia, por lo que la interpretación de resultados (P7-P8) es necesariamente estructural y no temática.

Table 1: Estadísticas básicas de la red

Estadística	Valor
Número de nodos n	5 561
Número de aristas m	191 255
Grado de entrada medio $\bar{d}^{\text{in}}$	34.39
Grado de salida medio $\bar{d}^{\text{out}}$	34.39
Nodo de mayor grado de entrada (ID original)	516 (in-degree = 1065)
Densidad $m/(n(n-1))$	0.006186
Nodos colgantes (out-degree = 0)	99 (1.78%)

Nota: $\bar{d}^{\text{in}} = \bar{d}^{\text{out}}$ coincide siempre en cualquier grafo dirigido, pues ambos son m/n ; es una identidad algebraica, no una particularidad de esta red.

2 P2 – Pregunta e hipótesis inicial

Pregunta. ¿Qué artículos son los más influyentes o centrales dentro de la Wikipedia en kashubio, entendiendo “influyente” como el artículo hacia el cual convergería con mayor frecuencia un lector que navegara la enciclopedia siguiendo enlaces al azar durante un tiempo prolongado?

Hipótesis inicial (formulada *antes* de calcular PageRank, en base a la exploración preliminar de P1). Esperamos que los nodos con mayor grado de entrada concentren también el mayor PageRank, ya que en redes de hipervínculos wiki los artículos “hub” (por ejemplo países, años o entidades administrativas muy referenciadas) suelen ser enlazados desde una gran cantidad de artículos distintos. Sin embargo, dado que la red tiene densidad baja (0.62%) y nodos colgantes, anticipamos que **PageRank y grado de entrada no coincidirán perfectamente**: deberían aparecer artículos con in-degree moderado pero enlazados desde otros nodos ya influyentes (importancia heredada recursivamente), fenómeno que cuantificamos en P6.

3 P3 – Análisis exploratorio de la red

(a) Distribución de grados

La Figura 1 muestra la distribución del grado de entrada y de salida en escala log-log. Ambas exhiben la forma característica de *ley de potencia* típica de redes de hipervínculos: la gran mayoría de los artículos tiene pocos enlaces, mientras que un número reducido de “hubs” concentra grados muy altos (hasta 1065 entrantes, hasta 396 salientes).




Figure 1: Distribución del grado de entrada y de salida (escala log-log).

(b) Nodos colgantes

Identificamos **99 nodos colgantes** (1.78% del total), es decir, artículos sin ningún enlace saliente. Son problemáticos porque generan **columnas enteras de ceros** en la matriz de hipervínculos H : un lector que “cae” en uno de esos artículos quedaría atrapado ahí bajo el modelo de marcha aleatoria puro, y esa columna no suma 1, rompiendo la propiedad column-estocástica necesaria para que exista una distribución estacionaria bien definida. Esto se resuelve en P4 reemplazando cada columna cero de H por el vector uniforme $\mathbf{1}/n$ al construir S , modelando que el lector “teletransporta” a cualquier otro artículo con probabilidad uniforme al llegar a un nodo sin salidas.

(c) Top-10 nodos por grado

La Figura 2 y la Tabla 2 muestran los diez nodos con mayor grado de entrada y de salida. Los nodos **516** (in-degree 1065) y **2646** (1013) destacan muy por sobre el resto, consistente con la hipótesis de P2. En grado de salida los diez primeros están mucho más apretados entre sí (393–396), sugiriendo un grupo de artículos de tipo “índice o listado” con estructura similar, más que un único hub dominante de salida.




Figure 2: Nodos con mayor grado de entrada y de salida.

Table 2: Top-10 nodos por grado de entrada

Rango	ID original	Grado de entrada
1	516	1065
2	2646	1013
3	21	818
4	465	812
5	430	812
6	467	808
7	449	807
8	434	807
9	443	804
10	463	803

(d) Conectividad

La red **no es fuertemente conexa**: tiene 2 748 componentes fuertemente conexas (SCC), con una componente gigante de 2 682 nodos ($\approx 48\%$ de la red) y el resto de tamaño trivial. Débilmente sí es casi toda una sola pieza (5 437 de 5 561 nodos en una única componente débilmente conexa). Esto es exactamente el escenario que motiva la teoría vista en clases: aunque el grafo original *no* es fuertemente conexo, la Matriz de Google $G = \alpha S + \frac{1-\alpha}{n} \mathbf{1}\mathbf{1}^T$ es **siempre irreducible** (todas sus entradas son estrictamente positivas gracias al término de teletransporte), por lo que G tiene una distribución estacionaria única independientemente de la fragmentación del grafo subyacente.

4 P4 – Construcción de la Matriz de Google

(a) Matriz de hipervínculos H

Definimos $H \in \mathbb{R}^{n \times n}$ con entradas

$$H_{ij} = \begin{cases} \frac{1}{\text{out}(j)} & \text{si } j \rightarrow i \\ 0 & \text{si no,} \end{cases}$$

donde $\text{out}(j)$ es el grado de salida del nodo j . Construimos H en formato disperso (`scipy.sparse`), dado que $n = 5\,561$ y una matriz densa desperdiciaría memoria y tiempo de cómputo innecesariamente (más del 99% de las entradas de H son cero, ya que $m/n^2 \approx 0.0062$).

Cada columna j de H suma exactamente 1 cuando el nodo fuente no es colgante: el nodo j reparte su “peso” de salida en partes iguales ($1/\text{out}(j)$) entre sus $\text{out}(j)$ vecinos, distribuyendo exactamente una unidad de probabilidad. Verificamos computacionalmente que las 5 462 columnas no colgantes suman 1 y las 99 columnas colgantes (identificadas comparando $\text{out}(j) = 0$) suman 0, representando el 1.78% de las columnas.

(b) Matriz columna-estocástica S

Reparamos los nodos colgantes reemplazando cada columna cero de H por el vector $\mathbf{1}/n$:

$$S = H + \frac{1}{n} \mathbf{a} \mathbf{1}^T, \quad a_j = \begin{cases} 1 & \text{si } j \text{ es colgante} \\ 0 & \text{si no.} \end{cases}$$

Verificamos que todas las columnas de S suman 1: para una columna no colgante, $S_{:,j} = H_{:,j}$ (suma 1) + 0; para una columna colgante, $S_{:,j} = \mathbf{0}$ (suma 0 en H) + $(1/n) \cdot n = 1$.

(c) Matriz de Google G

$$G = \alpha S + \frac{1-\alpha}{n} \mathbf{1} \mathbf{1}^T, \quad \alpha = 0.85.$$

Justificamos $\alpha = 0.85$ por ser el valor clásico propuesto por Brin y Page y el utilizado en los apuntes del curso: equilibra la fidelidad a la estructura real de enlaces (S) con la garantía teórica de ergodicidad.

Todas las entradas de G son estrictamente positivas: $G_{ij} = \alpha S_{ij} + \frac{1-\alpha}{n}$. Como $S_{ij} \geq 0$ siempre (es una probabilidad) y $\frac{1-\alpha}{n} > 0$ estrictamente (pues $\alpha = 0.85 < 1$), la suma es estrictamente positiva para *toda* entrada (i, j) , sin importar la estructura del grafo original. Esto garantiza que G sea irreducible y aperiódica (ergódica), como se vio en clases.

Nota de implementación: dado que $n = 5\,561$, una matriz G densa tendría ≈ 31 millones de entradas (≈ 247 MB en `float64`). Para una multiplicación matriz-vector eficiente, nunca materializamos S ni G de forma densa; en su lugar aplicamos la identidad algebraica

$$G\mathbf{r} = \alpha(H\mathbf{r}) + \frac{\alpha}{n} \left(\sum_j a_j r_j \right) + \frac{1-\alpha}{n} \left(\sum_i r_i \right)$$

directamente sobre el vector $\mathbf{r}$ en cada iteración (ver P5).

5 P5 – Cálculo del PageRank mediante iteración de potencias

(a) Iteración de potencias

Partiendo de $\mathbf{r}^{(0)} = \mathbf{1}/n$, iteramos $\mathbf{r}^{(k+1)} = G\mathbf{r}^{(k)}$ hasta que $\|\mathbf{r}^{(k+1)} - \mathbf{r}^{(k)}\|_1 < \varepsilon$, con $\varepsilon = 10^{-10}$. La convergencia se alcanzó en **105 iteraciones**.

(b) Curva de convergencia

La Figura 3 muestra $\|\mathbf{r}^{(k)} - \mathbf{r}^*\|_1$ en función de k (distancia de cada iterado al PageRank final $\mathbf{r}^*$), en escala logarítmica. El decaimiento es prácticamente lineal en esta escala, confirmando un decaimiento **geométrico**: la razón de decaimiento estimada (mediana de los cocientes consecutivos en el régimen estable) es **0.8497**, esencialmente $\alpha = 0.85$, tal como predice la teoría (la tasa de convergencia de la iteración de potencias está acotada por $|\lambda_2/\lambda_1| \leq \alpha$).




Figure 3: Curva de convergencia de la iteración de potencias.

(c) Verificación de propiedades

Verificamos que $\|\mathbf{r}^*\|_1 = 1.0000000000$ y que $r_i^* > 0$ para todo i (mínimo = 2.816×10^{-5}). Ambas propiedades están garantizadas por la teoría: G es columna-estocástica, por lo que conserva la norma 1 en cada iteración (como $\mathbf{r}^{(0)}$ tiene suma 1, $\|\mathbf{r}^{(k)}\|_1 = 1$ para todo k , incluido el límite). La positividad estricta se debe a que G tiene todas sus entradas > 0 (P4): $\mathbf{r}^* = G\mathbf{r}^*$ es una combinación positiva de un vector no negativo y no nulo, por lo que $r_i^* > 0$ para todo i .

(d) Top-20 nodos por PageRank

Table 3: Los 20 nodos de mayor PageRank

Rango	ID original	PageRank (r^*)	Grado de entrada	Grado de salida
1	516	0.018401	1065	89
2	2646	0.014109	1013	56
3	488	0.009297	267	104
4	463	0.008610	803	44
5	453	0.008406	377	43
6	21	0.008142	818	43
7	465	0.008090	812	43
8	434	0.008021	807	44
9	430	0.008004	812	42
10	449	0.007984	807	44
11	467	0.007962	808	44
12	458	0.007937	797	44
13	23	0.007893	379	378
14	441	0.007867	796	44
15	18	0.007864	261	94
16	443	0.007862	804	43
17	469	0.007856	797	43
18	517	0.007823	302	70
19	2101	0.007776	588	28
20	782	0.007179	297	83

6 P6 – PageRank vs. grado de entrada

(a) Comparación y correlación

La Figura 4 compara el grado de entrada con el PageRank de cada nodo. El coeficiente de correlación de Pearson entre ambas medidas es **0.3801** ($p \approx 1.4 \times 10^{-190}$): positivo pero *moderado*, no fuerte. Esto confirma cuantitativamente que el in-degree explica solo parte de la importancia real capturada por PageRank.




Figure 4: PageRank vs. grado de entrada (escala log-log), con el top-10 de PageRank destacado.

(b) Nodos discordantes

Comparando por *rango* (posición relativa) en vez de valor crudo, identificamos casos claros de discordancia:

- **Alto in-degree, PageRank relativamente bajo:** varios nodos con in-degree 424 (empata-dos en el rango 49 de grado de entrada) caen hasta el rango $\approx 730\text{--}977$ en PageRank. Reciben muchos enlaces, pero probablemente desde artículos de baja relevancia propia, por lo que su importancia heredada es escasa.
- **PageRank alto, in-degree moderado:** el caso más extremo es el nodo **1554**, con solo 17 enlaces entrantes (rango 611 de 5 561) pero un PageRank que lo ubica en el rango **48** de toda la red. Recibe pocos enlaces, pero probablemente desde uno o dos hubs muy influyentes (como el nodo 516), heredando concentradamente importancia de muy pocas fuentes de alto valor.

Este es exactamente el fenómeno que PageRank está diseñado para capturar y que un conteo simple de enlaces entrantes no puede ver: importa *quién* enlaza, no solo *cuántos* enlazan.

7 P7 – Interpretación de resultados

(a) Nodos de mayor PageRank

Dado que este dataset de KONECT no incluye títulos de artículo (solo IDs internos), la interpretación de por qué estos nodos son influyentes es necesariamente estructural: los nodos **516** y **2646** combinan in-degree muy alto y out-degree moderado-alto (89 y 56 respectivamente), funcionando como verdaderos hubs bidireccionales de navegación – reciben de muchos artículos y a la vez enlazan hacia otros nodos importantes, propagando recursivamente su propio peso.

(b) Subgrafo inducido

La Figura 5 muestra el subgrafo inducido por los 40 nodos de mayor PageRank, con tamaño de nodo proporcional a su PageRank. Como esta red no trae atributos temáticos naturales, coloreamos según la pertenencia a la componente fuertemente conexa (SCC) gigante calculada en P3(d) – un atributo estructural real de la red. El **100%** de los 40 nodos de mayor PageRank pertenece a la SCC gigante, aunque esta solo cubre el 48% de la red completa: ningún nodo periférico se cuela entre los influyentes. Además, la densidad del subgrafo top-40 (0.183) es **≈ 30 veces** la densidad global de la red (0.0062): los nodos influyentes están mucho más interconectados entre sí que el resto de la red.




Figure 5: Subgrafo inducido por los 40 nodos de mayor PageRank.

(c) Atributos naturales

Esta red no trae etiquetas temáticas (a diferencia, por ejemplo, de una red de blogs políticos con orientación etiquetada), por lo que no es posible evaluar si el top-PageRank pertenece a un grupo temático particular – limitación real de los datos disponibles, documentada aquí en vez de asumida o simulada.

8 P8 – Discusión, limitaciones y conclusiones

¿Se cumplió la hipótesis? Parcialmente. Acertamos en que los nodos de mayor in-degree (516, 2646) también lideran el PageRank, pero la correlación de solo 0.38 y los casos de discordancia de

P6 muestran que **la estructura recursiva domina sobre el conteo bruto de enlaces**, tal como anticipaba la segunda parte de nuestra hipótesis inicial.

Limitaciones del método y de los datos.

- El modelo de marcha aleatoria tiene sentido en este contexto: es literalmente cómo navega un lector siguiendo hipervínculos.
- Los 99 nodos colgantes (1.8%) son pocos y quedan bien manejados por S ; no distorsionan de forma importante el resultado global.
- La red es dispersa (densidad 0.62%), régimen normal para redes de hipervínculos donde PageRank es informativo (en una red casi completa todos los nodos tendrían PageRank similar y el método perdería poder discriminante).
- La limitación más importante: **sin nombres de artículo no podemos validar semánticamente** qué son los nodos 516 o 2646 – nuestro análisis es puramente estructural, no de contenido.

Preguntas nuevas. El hallazgo más claro que no anticipamos es que el núcleo de los 40 nodos con mayor PageRank resultó ser ≈ 30 veces más denso que la red completa (P7b) – esto abre la pregunta de **por qué los nodos influyentes están tan concentrados entre sí**, algo que no exploramos más allá de constatarlo. También queda abierta la pregunta de **qué hace que un nodo con in-degree alto reciba PageRank bajo** (P6b): ¿viene principalmente de otros nodos con PageRank bajo? No pudimos profundizar en esto porque el dataset no incluye los títulos de los artículos, así que no hay forma de inspeccionar el contenido real de esos nodos “discordantes”.

Explicación para alguien sin conocimientos técnicos. Un puñado de artículos de la Wikipedia en kashubio actúan como “estaciones centrales” de la enciclopedia – no simplemente porque muchos artículos los mencionen, sino porque los artículos que sí los mencionan son a su vez importantes. Es como ser recomendado por gente influyente en vez de por muchos desconocidos: cuenta más *quién* te enlaza que *cuántos* te enlazan.

Reproducibilidad

El código completo (construcción de H , S , G , iteración de potencias implementada desde cero, y todas las figuras de este informe) está disponible, junto con el notebook Jupyter y las instrucciones de ejecución, en el repositorio público de GitHub del grupo: <https://github.com/Fsli1822/IMT2230-Proyecto-2>. Los datos originales se obtienen de http://konect.cc/networks/wikipedia_link_csb/ y se descargan automáticamente al ejecutar el notebook.